

1 Expressions régulières

Definition 1 Un **alphabet** est un ensemble fini de symbole appelé **lettre**. On prend souvent la notation Σ pour représenter un **alphabet**.

Definition 2 Un **langage** sur un alphabet Σ , noté L est un sous-ensemble de Σ^* .

Definition 3 Soit Σ un alphabet, les **expressions régulières** sur Σ sont définies récursivement comme suit.

Cas de base :

- \emptyset , est l'**expression** représentant l'ensemble vide,
- ϵ est l'**expression** représentant l'ensemble $\{\epsilon\}$,
- $\forall a \in \Sigma$, a est l'**expression** représentant l'ensemble $\{a\}$,

Cas héréditaire :

Soit r, r' deux **expressions régulières** représentant respectivement les langages $R, R' \in (\Sigma^*)^2$, on a définie les opérateurs ci-dessous sur l'ensemble des **expressions régulières** de Σ que l'on note E_Σ ,

- $r + r'$ représente le langage dénoté par $R \cup R'$,
- $r.r'$ représente le langage dénoté par $R.R'$,
- r^* représente le langage dénoté par R^* .

Definition 4 Sera noté $E_{(\Sigma, \mathbb{N})}$, l'ensemble des **expressions régulières** sur l'alphabet Σ au quelle aura été associé à chaque lettre son indice d'apparition dans l'ordre de lecture gauche-droite de chacune des expressions.

Definition 5 Avec $r \in E_Q$, on note $L(r)$, le **langage** représenté par l'**expression régulière** r .

Definition 6 On définit la fonction **linéarisation** de la façon suivante,

$$linearisation :: E_\Sigma \rightarrow E_{(\Sigma, \mathbb{N})}$$

Definition 7 Sur une *expression régulière* $r \in E_Q$, on note la fonction renvoyant l'ensemble des premières lettres du langage représenté par r comme étant $first(r)$. Cette fonction est définie de récursivement comme suit :

$$\begin{aligned} first(\emptyset) &= first(\epsilon) = \emptyset \\ first(x) &= \{x\}, x \in Q \\ first(f + g) &= first(f) \cup first(g) \\ first(f.g) &= \begin{cases} first(f), & \text{si } \epsilon \notin L(f) \\ first(f) \cup first(g), & \text{si } \epsilon \in L(f) \end{cases} \\ first(f^*) &= first(f) \end{aligned}$$

Avec $(f, g) \in (E_Q)^2$

Definition 8 De même, on définit la fonction $last(r)$ permettant de renvoyer à partir d'une **expression régulière** l'ensemble des dernières lettres de tous les mots du langage représenté par r . Tout comme la fonction $first$, $last$ est définie de la même façon récursivement sauf pour le cas suivant :

$$last(f.g) = \begin{cases} last(g), & \text{si } \epsilon \notin L(g) \\ last(f) \cup last(g), & \text{si } \epsilon \in L(g) \end{cases}$$

Definition 9 Nous définissons la fonction $index$, comme prenant en paramètre une expression régulière indexée et retournant une table permettant d'obtenir la fonction suivante :

$$lookup :: Map(Int, \Sigma) \rightarrow Int \rightarrow Maybe(\Sigma)$$

Renvoyant *Nothing*, en cas de non présence de l'indice passé en paramètre dans l'expression, sinon renvoie *Just* la valeur d'indice associé dans l'expression.

Definition 10 On définit la fonction $follow$, comme un moyen d'obtenir les possibles symboles qui peuvent suivre une certaine lettre dans une **expression régulière**. Cette fonction a la signature suivante :

$$follow :: E_{(\Sigma, \mathbb{N})} \rightarrow (Int \rightarrow 2^{\Sigma \times \mathbb{N}})$$

Retournant pour l'indice d'un élément d'une **expression régulière**, l'ensemble des éléments indexés qui peuvent le suivre.

2 Automate fini

Definition 11 On définit un **automate fini**, comme étant un cinq-uplet. On note généralement l'**automate** M , $M = (\Sigma, Q, I, F, \delta)$.

- Σ , est l'alphabet d'entrée,
- Q , l'ensemble des états,
- I , est un sous-ensemble de Q , il s'agit des états initiaux de l'**automate**,
- F , est un sous-ensemble de Q , il s'agit des états finaux de l'**automate**,
- δ est la fonction de transition définie de la façon suivante :

$$\delta :: Q \times \Sigma \rightarrow 2^Q$$

Definition 12 Un mot est accepté par un **automate**, $M = (\Sigma, Q, I, F, \delta)$ si et seulement si, il existe au moins une suite de d'état tel que $m = (p_0, \dots, p_{n-1})$ tel que $p_0 \in I$ et $p_{n-1} \in F$.

Definition 13 On définit le langage d'un automate $M = (\Sigma, Q, I, F, \delta)$, comme étant $L(M) = \{w \in \Sigma^* | w \text{ est reconnu par } M\}$

Definition 14

- [1] Valentin Antimirov, *Partial derivatives of regular expressions and finite automaton constructions*
- [2] Marc Chemillier, *TL Support De Cours*,
<https://infosetif.do.am/S4/TL/TL-SupportDeCours-MarcChemillier.pdf>.
Consulté le June 2, 2024.
- [3] Pascal Caron, Djelloul Ziadi, *Characterization of Glushkov automata*